电话客服对话理解 - 第二阶段 E2E 报告

真实 Web / API / Session / Context / RAG · Microsoft Edge · 无业务接口 Mock
模型固定：qwen3.5-flash（禁止静默切换）

11	2	8	1	20.0%
总用例	通过	失败	BLOCKED	可执行通过率

测试环境与代码版本

Web / API	http://localhost:3000 / http://localhost:3001	**浏览器**	Microsoft Edge, channel=msedge, headless=true
代码版本	afb5b48 + working tree changes	**执行时间**	2026-10-13T02:25:12.396Z - 2026-10-13T02:26:42.598Z
LLM	qwen3.5-flash	**Playwright workers**	1
平均模型耗时	1038.3 ms	**LLM 调用 / Token**	22 次 / 7383

通过率分母排除 BLOCKED/SKIPPED；模型故障不会归为业务缺陷，也不会伪造 PASS。

测试结论汇总

测试用例编号	场景	结论
DU-01	DU-01 · A→A · 省略指代	FAIL 测试失败：预期 consult，实际 clarify。
DU-02	DU-02 · A→A · 补充解释	FAIL 测试失败：预期 continue，实际 extend。
DU-03	DU-03 · A→A · 关联延伸	PASS 实际对话理解结果与预期一致。
DU-04	DU-04 · A→A · 条件追加	FAIL 测试失败：预期 consult，实际 clarify。
DU-05	DU-05 · A→A · 重复确认	PASS 实际对话理解结果与预期一致。
DU-06	DU-06 · A→B · 新话题切换	FAIL 测试失败：预期 delete，实际 query。
DU-08	DU-08 · 多话题 · 多话题并行	FAIL 测试失败：预期 create，实际 consult。
DU-09	DU-09 · 多话题 · 话题结束	BLOCKED qwen3.5-flash 模型调用异常，本用例未形成有效业务结论。
DU-12	DU-12 · 信息处理 · 问题补充	FAIL 测试失败：预期 query，实际 clarify。
DU-13	DU-13 · 信息处理 · 否定重述	FAIL 测试失败：预期 continue，实际 switch。
DU-16	DU-16 · 澄清 · 信息冲突	FAIL 测试失败：Received: "删除凭证"

失败与阻塞说明

测试用例编号	状态	原因	建议
DU-01	FAIL	预期 consult，实际 clarify。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-02	FAIL	预期 continue，实际 extend。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-04	FAIL	预期 consult，实际 clarify。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-06	FAIL	预期 delete，实际 query。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-08	FAIL	预期 create，实际 consult。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-09	BLOCKED	qwen3.5-flash 调用故障，未将规则降级结果冒充为模型理解结果	为当前 API 账户充值或恢复额度后原样复测；禁止切换模型。
DU-12	FAIL	预期 query，实际 clarify。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-13	FAIL	预期 continue，实际 switch。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-16	FAIL	Received: "删除凭证"	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。

逐用例完整对话截图与结论

测试用例编号：DU-01

场景：DU-01 · A→A · 省略指代

完整对话截图



结论： FAIL 测试失败：预期 consult，实际 clarify。

测试用例编号：DU-02

场景：DU-02 · A→A · 补充解释

完整对话截图



结论： FAIL 测试失败：预期 continue，实际 extend。

测试用例编号：DU-03

场景：DU-03 · A→A · 关联延伸

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-04

场景：DU-04 · A→A · 条件追加

完整对话截图



结论： FAIL 测试失败：预期 consult，实际 clarify。

测试用例编号：DU-05

场景：DU-05 · A→A · 重复确认

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-06

场景：DU-06 · A→B · 新话题切换

完整对话截图



结论： FAIL 测试失败：预期 delete，实际 query。

测试用例编号：DU-08

场景：DU-08 · 多话题 · 多话题并行

完整对话截图



结论： FAIL 测试失败：预期 create，实际 consult。

测试用例编号：DU-09

场景：DU-09 · 多话题 · 话题结束

完整对话截图



结论： BLOCKED qwen3.5-flash 模型调用异常，本用例未形成有效业务结论。

测试用例编号：DU-12

场景：DU-12 · 信息处理 · 问题补充

完整对话截图



结论： FAIL 测试失败：预期 query，实际 clarify。

测试用例编号：DU-13

场景：DU-13 · 信息处理 · 否定重述

完整对话截图



结论： FAIL 测试失败：预期 continue，实际 switch。

测试用例编号：DU-16

场景： DU-16 · 澄清 · 信息冲突

完整对话截图



结论： FAIL 测试失败：Received: "删除凭证"