电话客服对话理解 - 第二阶段 E2E 报告

真实 Web / API / Session / Context / RAG · Microsoft Edge · 无业务接口 Mock
模型固定：qwen3.5-flash（禁止静默切换）

29	18	11	0	62.1%
总用例	通过	失败	BLOCKED	可执行通过率

测试环境与代码版本

Web / API	http://localhost:3000 / http://localhost:3001	**浏览器**	Microsoft Edge, channel=msedge, headless=true
代码版本	afb5b48 + working tree changes	**执行时间**	2026-10-13T03:09:29.896Z - 2026-10-13T03:12:43.143Z
LLM	qwen3.5-flash	**Playwright workers**	1
平均模型耗时	1068.9 ms	**LLM 调用 / Token**	32 次 / 11422

通过率分母排除 BLOCKED/SKIPPED；模型故障不会归为业务缺陷，也不会伪造 PASS。

测试结论汇总

测试用例编号	场景	结论
DU-01	DU-01 · A→A · 省略指代	FAIL 测试失败：预期 consult，实际 clarify。
DU-02	DU-02 · A→A · 补充解释	FAIL 测试失败：预期 continue，实际 extend。
DU-03	DU-03 · A→A · 关联延伸	PASS 实际对话理解结果与预期一致。
DU-04	DU-04 · A→A · 条件追加	FAIL 测试失败：预期 continue，实际 extend。
DU-05	DU-05 · A→A · 重复确认	PASS 实际对话理解结果与预期一致。
DU-06	DU-06 · A→B · 新话题切换	FAIL 测试失败：预期 delete，实际 query。
DU-07	DU-07 · A→B→A · 历史话题恢复	PASS 实际对话理解结果与预期一致。
DU-08	DU-08 · 多话题 · 多话题并行	FAIL 测试失败：预期 create，实际 consult。
DU-09	DU-09 · 多话题 · 话题结束	FAIL 测试失败：预期 query，实际 clarify。
DU-10	DU-10 · 信息处理 · 槽位补充	PASS 实际对话理解结果与预期一致。
DU-11	DU-11 · 信息处理 · 信息纠正	PASS 实际对话理解结果与预期一致。
DU-12	DU-12 · 信息处理 · 问题补充	FAIL 测试失败：预期 query，实际 clarify。
DU-13	DU-13 · 信息处理 · 否定重述	FAIL 测试失败：预期 continue，实际 switch。
DU-14	DU-14 · 澄清 · 指代歧义	FAIL 测试失败：预期 update，实际 query。
DU-15	DU-15 · 澄清 · 问题模糊	FAIL 测试失败：预期 consult，实际 clarify。
DU-16	DU-16 · 澄清 · 信息冲突	FAIL 测试失败：Received: "删除凭证"
DU-17	DU-17 · 特殊意图 · 闲聊	PASS 实际对话理解结果与预期一致。
DU-18	DU-18 · 特殊意图 · 结束	PASS 实际对话理解结果与预期一致。

测试用例编号	场景	结论
DU-19	DU-19 · 特殊意图 · 转人工	PASS 实际对话理解结果与预期一致。
DU-20	DU-20 · 异常 · LLM 调用失败安全降级	PASS 实际对话理解结果与预期一致。
DU-21	DU-21 · 会话 · 不同通话隔离	PASS 实际对话理解结果与预期一致。
TC-PHONE-01	TC-PHONE-01 · T01 Session 创建：网页与 Agent 使用同一 Session	PASS 实际对话理解结果与预期一致。
TC-PHONE-02	TC-PHONE-02 · T02 同一 Session 连续三轮且无重复写入	PASS 实际对话理解结果与预期一致。
TC-PHONE-03	TC-PHONE-03 · T03 历史信息完整保存	PASS 实际对话理解结果与预期一致。
TC-PHONE-04	TC-PHONE-04 · T04 多话题历史保留	PASS 实际对话理解结果与预期一致。
TC-PHONE-05	TC-PHONE-05 · T05 不同 Session 隔离	PASS 实际对话理解结果与预期一致。
TC-PHONE-06	TC-PHONE-06 · T06 页面刷新后可从网页会话列表恢复	PASS 实际对话理解结果与预期一致。
TC-PHONE-07	TC-PHONE-07 · T07 上下文窗口会截断但会话历史仍完整	PASS 实际对话理解结果与预期一致。
TC-PHONE-08	TC-PHONE-08 · T08 网页会话结束并清理	PASS 实际对话理解结果与预期一致。

失败与阻塞说明

测试用例编号	状态	原因	建议
DU-01	FAIL	预期 consult，实际 clarify。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-02	FAIL	预期 continue，实际 extend。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-04	FAIL	预期 continue，实际 extend。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-06	FAIL	预期 delete，实际 query。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-08	FAIL	预期 create，实际 consult。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-09	FAIL	预期 query，实际 clarify。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-12	FAIL	预期 query，实际 clarify。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-13	FAIL	预期 continue，实际 switch。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-14	FAIL	预期 update，实际 query。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-15	FAIL	预期 consult，实际 clarify。	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。
DU-16	FAIL	Received: "删除凭证"	根据实际结构化输出修复 DialogueUnderstanding，不修改预期标准。

逐用例完整对话截图与结论

测试用例编号：DU-01

场景：DU-01 · A→A · 省略指代

完整对话截图



结论： FAIL 测试失败：预期 consult，实际 clarify。

测试用例编号：DU-02

场景：DU-02 · A→A · 补充解释

完整对话截图



结论： FAIL 测试失败：预期 continue，实际 extend。

测试用例编号：DU-03

场景：DU-03 · A→A · 关联延伸

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-04

场景：DU-04 · A→A · 条件追加

完整对话截图



结论： FAIL 测试失败：预期 continue，实际 extend。

测试用例编号：DU-05

场景：DU-05 · A→A · 重复确认

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-06

场景：DU-06 · A→B · 新话题切换

完整对话截图



结论： FAIL 测试失败：预期 delete，实际 query。

测试用例编号：DU-07

场景：DU-07 · A→B→A · 历史话题恢复

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-08

场景：DU-08 · 多话题 · 多话题并行

完整对话截图



结论： FAIL 测试失败：预期 create，实际 consult。

测试用例编号：DU-09

场景：DU-09 · 多话题 · 话题结束

完整对话截图



结论： FAIL 测试失败：预期 query，实际 clarify。

测试用例编号：DU-10

场景：DU-10 · 信息处理 · 槽位补充

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-11

场景：DU-11 · 信息处理 · 信息纠正

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-12

场景：DU-12 · 信息处理 · 问题补充

完整对话截图



结论： FAIL 测试失败：预期 query，实际 clarify。

测试用例编号：DU-13

场景：DU-13 · 信息处理 · 否定重述

完整对话截图



结论： FAIL 测试失败：预期 continue，实际 switch。

测试用例编号：DU-14

场景：DU-14 · 澄清 · 指代歧义

完整对话截图

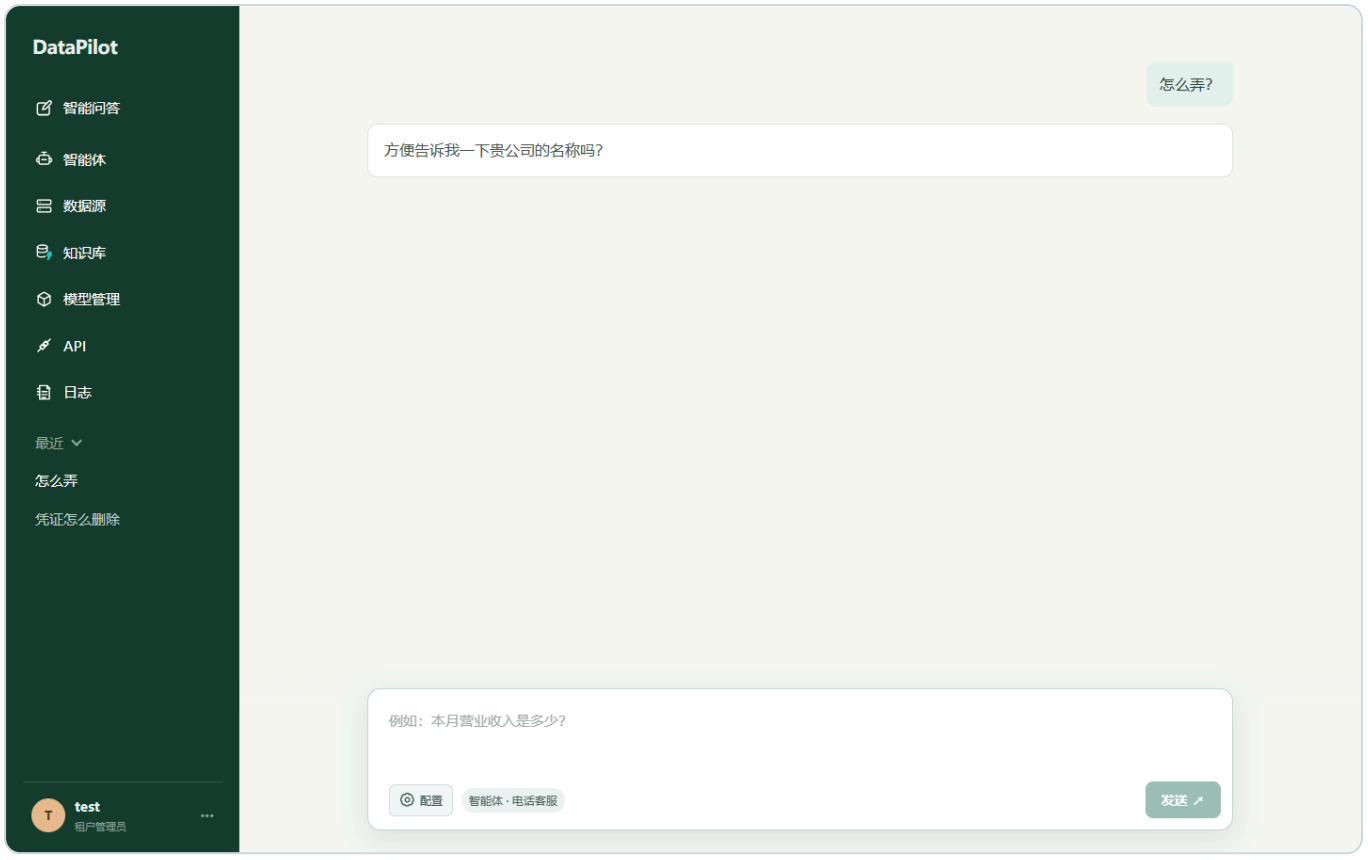


结论： FAIL 测试失败：预期 update，实际 query。

测试用例编号：DU-15

场景：DU-15 · 澄清 · 问题模糊

完整对话截图



结论： FAIL 测试失败：预期 consult，实际 clarify。

测试用例编号：DU-16

场景：DU-16 · 澄清 · 信息冲突

完整对话截图

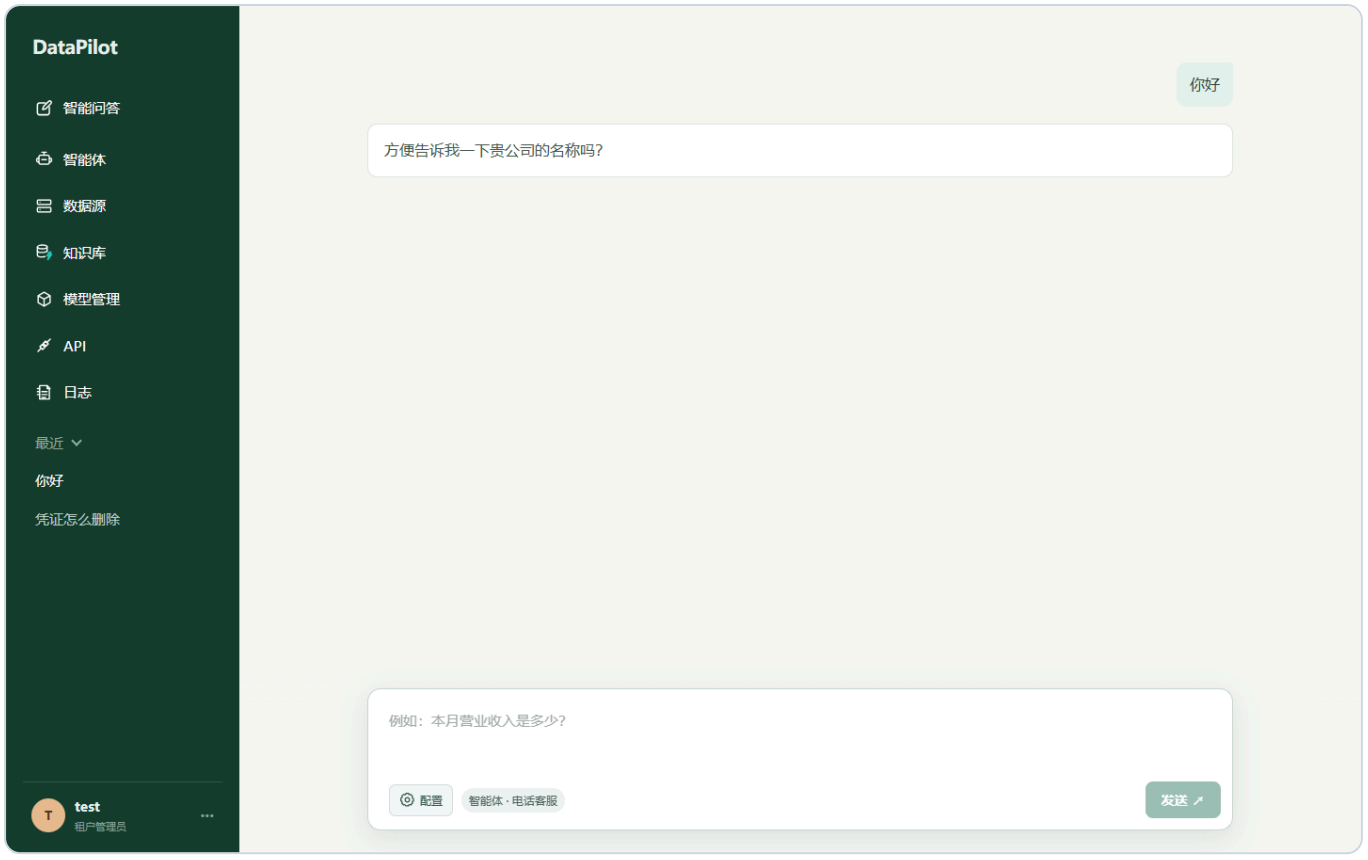


结论： FAIL 测试失败：Received: "删除凭证"

测试用例编号：DU-17

场景：DU-17 · 特殊意图 · 闲聊

完整对话截图

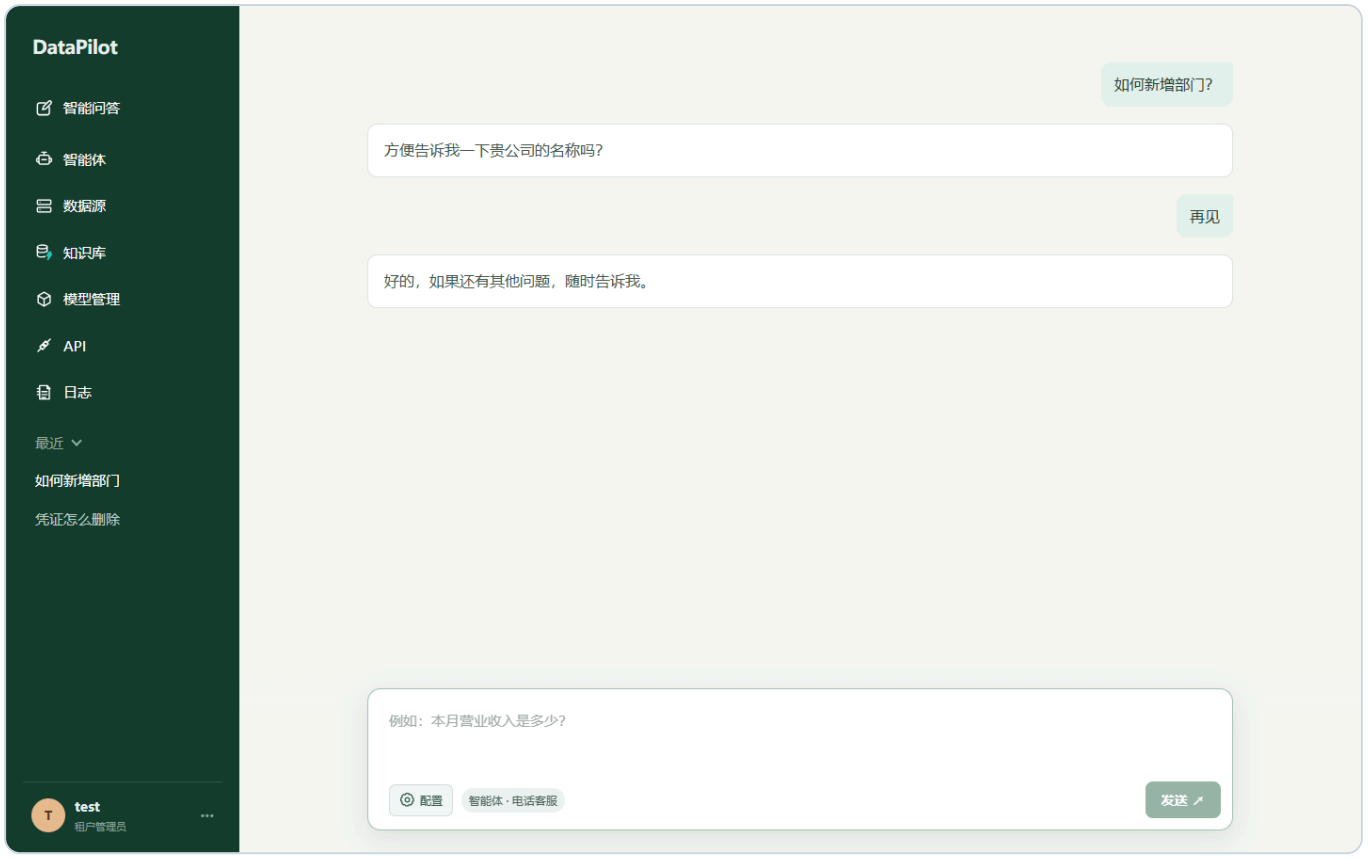


结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-18

场景：DU-18 · 特殊意图 · 结束

完整对话截图

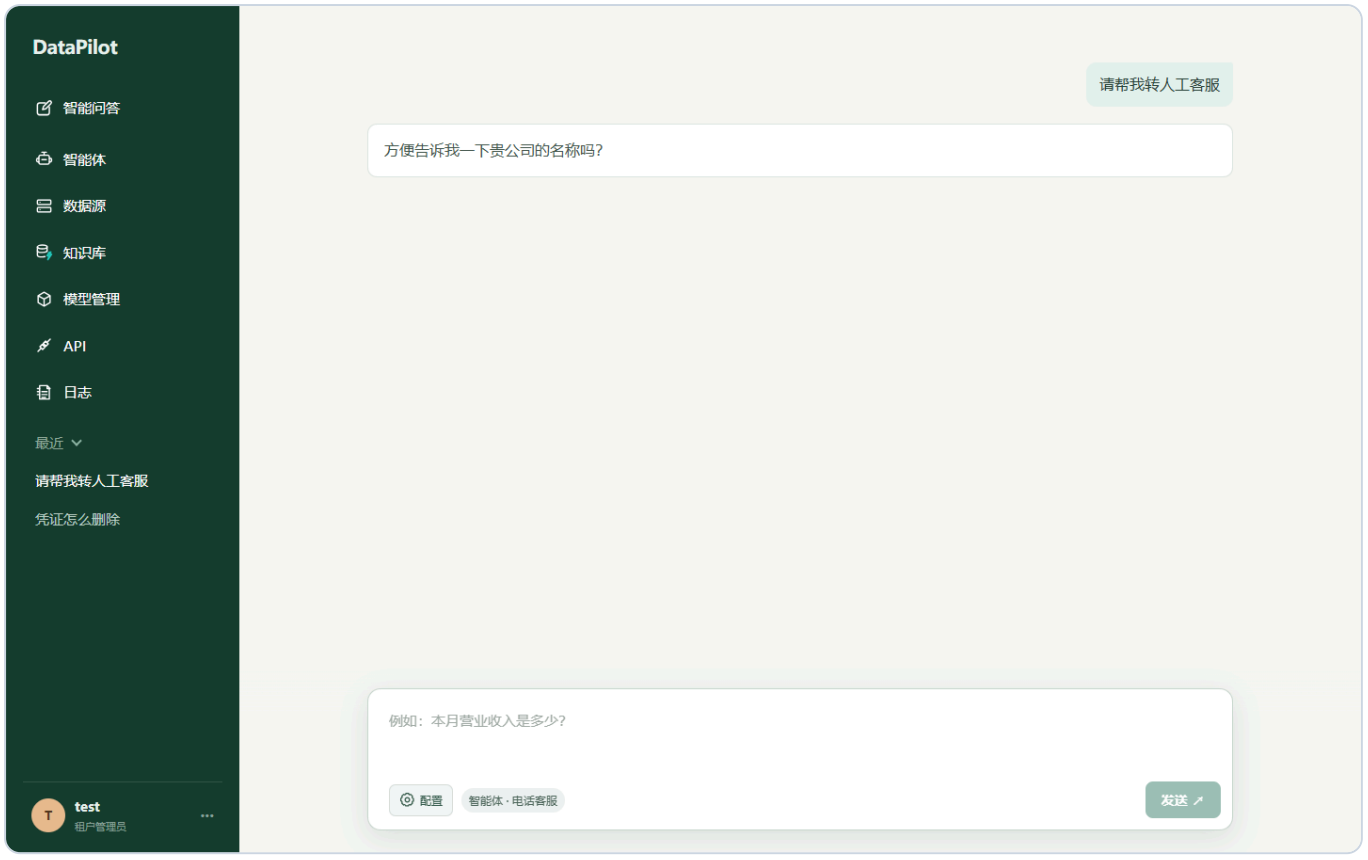


结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-19

场景：DU-19 · 特殊意图 · 转人工

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-20

场景：DU-20 · 异常 · LLM 调用失败安全降级

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：DU-21

场景：DU-21 · 会话 · 不同通话隔离

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：TC-PHONE-01

场景：TC-PHONE-01 · T01 Session 创建：网页与 Agent 使用同一 Session

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：TC-PHONE-02

场景：TC-PHONE-02 · T02 同一 Session 连续三轮且无重复写入

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：TC-PHONE-03

场景：TC-PHONE-03 · T03 历史信息完整保存

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：TC-PHONE-04

场景：TC-PHONE-04 · T04 多话题历史保留

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：TC-PHONE-05

场景：TC-PHONE-05 · T05 不同 Session 隔离

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：TC-PHONE-06

场景：TC-PHONE-06 · T06 页面刷新后可从网页会话列表恢复

完整对话截图

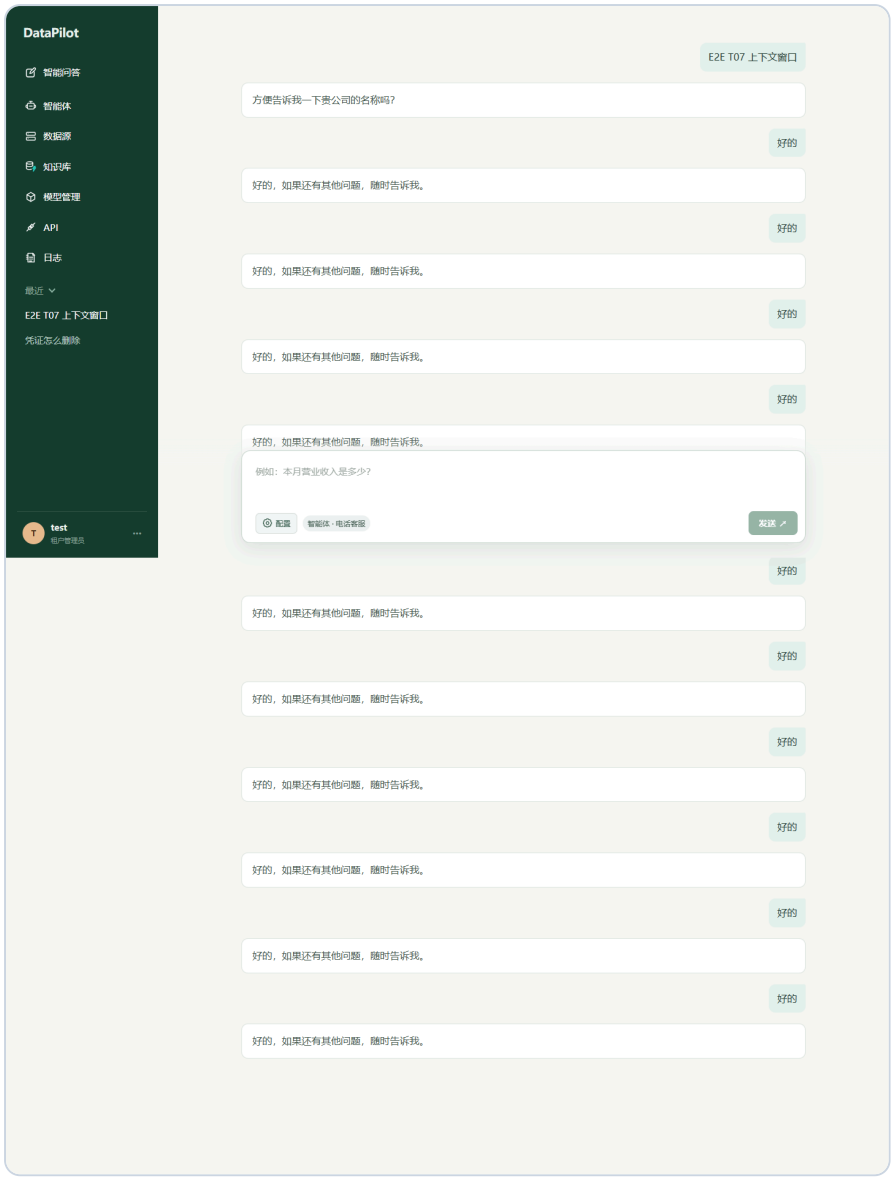


结论： PASS 实际对话理解结果与预期一致。

测试用例编号：TC-PHONE-07

场景：TC-PHONE-07 · T07 上下文窗口会截断但会话历史仍完整

完整对话截图



结论： PASS 实际对话理解结果与预期一致。

测试用例编号：TC-PHONE-08

场景：TC-PHONE-08 · T08 网页会话结束并清理

完整对话截图



结论： PASS 实际对话理解结果与预期一致。